

DilAjanları

Yerel Video Analiz ve Karar Destek Ajansı

Modelin Baştan Sona Anlatımı

TEKNOFEST 2026 · Türkçe Yapay Zekâ Dil Ajanları · 3. Senaryo

Takım VigilantAI · 11 Ağustos 2026

Tek cümleyle: DilAjanları, bir güvenlik kamerası videosunu tamamen yerel çalışan bir görsel-dil modeliyle izleyen, gördüğünü Türkçe olay listesine ve risk değerlendirmesine çeviren, gerektiğinde operasyonel fonksiyonları çağıran bir karar-destek ajanıdır.

Bu belge nasıl okunmalı. Bölümler birbirinin üzerine kurulur: önce sistemin ne yaptığı, sonra hangi parçalardan oluştuğu, sonra her parçanın içi, en sonda ölçümler ve sınırlar. Belgedeki her sayı depodan okunmuştur ve yanında kaynağı yazılıdır (dosya:satır veya sonuç dosyası adı). Kaynağı gösterilemeyen hiçbir rakam bu belgeye alınmamıştır.

1. Bir bakışta

Sisteme bir video verilir. Sistem videoyu izler ve operatöre şunları üretir:

- Videoda ne olduğunun zaman damgalı olay listesi (her olayda önem derecesi, kategori ve görüntüdeki konum bilgisi de vardır).
- Olayları birleştiren kısa Türkçe özet.
- Gerekçesiyle birlikte risk değerlendirmesi: Düşük, Orta, Yüksek veya Kritik.
- Operatörün uygulayabileceği aksiyon önerileri.
- Yalnızca gerçek yüksek-risk sinyalinde operasyonel fonksiyon çağrıları (sağlık ekibi yönlendirme, güvenlik uyarısı, alanı güvenliğe alma, acil durdurma, olay kaydı, yönetici bilgilendirme).
- Sistemin o kararlara neden vardığını adım adım gösteren karar günlüğü, ayrıca resmî olay tutanağı, SHA-256 imzalı kanıt paketi ve vardiya devir-teslim brifingi.

Sistem tamamen yereldir: model kendi bilgisayarımızda çalışır, internet bağlantısı ya da dış servis kullanılmaz.

En önemli rakamlar

Konu	Değer	Kaynak
Ajan düğümü sayısı	7 düğüm, 1 koşullu kenar	dilajan/agent/graph.py:1497-1522
Varsayılan model	Qwen/Qwen3-VL-8B-Instruct-FP8	dilajan/config.py:31
Kod büyüklüğü	6.374 satır (22 dosya)	wc -l, bu koşulda ölçüldü
Test	540 kontrol, 0 hata (7 dosya) + 27 istatistik testi	bu koşulda yeniden çalıştırıldı
Olay tespiti (senaryo seti, n=25)	24/25 = %96 [%80-%99]	query_ab_A_20260809_182957.json
Olay tespiti (holdout seti, n=24)	23/24 = %96 [%80-%99] · 24/24 = %100 [%86-%100]	eval_20260728_193430.json · naming_ab_A_20260810_210033.json
Normal videoda dar yanlış alarm	0/8 · 0/12 (üst sınır sıfır değildir)	aynı iki dosya
Hız	video saniyesi başına 0,66 sn; 4 eş-zamanlı koşulda 6,5 video/dakika	full_20260728_192334/performans.log:11 ve :17
Tepe VRAM	22.661 MB / 24 GB (model FP8 ~19 GB)	full_20260728_192334/performans.log:17 ve :19
Koşu-arası gürültü tabanı	tespitte 2/25 = %8 · adlandırmada 3/25 = %12	query_ab A ile A' karşılaştırması, bu koşulda hesaplandı

2. Sistem ne işe yarar?

Çözdüğü problem

Bir tesiste onlarca kamera vardır, izleyecek operatör sayısı ise sınırlıdır. Kayıtların çoğu olaysızdır; olayın olduğu birkaç dakikayı bulmak saatler alır. Klasik hareket-algılayıcılar ise "bir şey kımıldadı" der, ne olduğunu söylemez. Operatörün ihtiyacı bir alarm değil, okunabilir bir anlatımdır: ne oldu, ne zaman oldu, ne kadar ciddi, şimdi ne yapmalı.

DilAjanları tam bu boşluğu doldurur. Videoyu izler, gördüğünü Türkçe anlatır, önem derecesine göre sıralar ve gerekçesini gösterir. Operatör görüntüyü baştan sona izlemek yerine sistemin işaretlediği anlara bakar.

Kim kullanır?

Kullanıcı	Ne için kullanır
Güvenlik operatörü (canlı vardiya)	Kameradan gelen kaydı hızlıca tarayıp riskli anları öne çıkarmak; şüpheli bir ana dair sisteme soru sormak.
Vardiya amiri	Vardiya sonunda devir-teslim brifingi almak; olay tutanağı ve kanıt paketi üretmek.
İş güvenliği sorumlusu	Tesise özgü kuralları metin olarak tanımlayıp ("pano kapakları kapalı tutulur") ihlalleri işaretletmek.
İnceleme / soruşturma	Geçmiş kayıta belirli bir konuyu aramak: analiz sorgusu kutusuna serbest metin yazılır, sistem o konuya odaklanır.

Tipik senaryo

Operatör bir depo kamerasının kaydını yükler. Sistem videoyu 10 saniyelik parçalara böler, her parçayı ayrı ayrı inceler ve şunu üretir: 00:12'de makinenin yanında alev ve duman görüldü; 00:24'te personel alanı terk ediyor. Risk seviyesini Kritik olarak işaretler, gerekçesini yazar, güvenlik ekibi uyarısı ve olay kaydı fonksiyonlarını çağırır. Operatör karar günlüğünden sistemin bu sonuca hangi adımlarla vardığını görür ve onaylar.

Konulandırma — dürüst ifade

Sistem bugün operatörün yerine karar veren bir otonom alarm sistemi DEĞİLDİR. Ölçülen sınırlar (bölüm 14) bunu desteklemiyor. Sistem, operatöre yardımcı olan bir inceleme ve triyaj aracıdır. Operasyonel çağrılar öneri olarak sunulur ve operatör onayına bağlıdır.

3. Teknik yığın ve her seçimin gerekçesi

Aşağıdaki sürümler kurulu sanal ortamdan (importlib.metadata) bu koşumda okunmuştur; tahmin değildir.

Katman	Seçim	Neden bu seçim
Model	Qwen/Qwen3-VL-8B-Instruct-FP8 config.py:31	Görüntüyü ve metni birlikte anlayan açık kaynak model; Türkçesi akıcı. FP8 (8 bitlik sayı biçimi) sayesinde ağırlıklar ~19 GB'a iner ve 24 GB'lık karta KV önbelleğiyle birlikte sığar.
Yedek model	Qwen/Qwen2.5-VL-7B-Instruct serve_vllm.py:8	Hassasiyet öncelikli alternatif. Varsayılan değildir; DILAJAN_MODEL_NAME ile seçilir.
Servisleme	vLLM 0.23.0	Modeli yerelde OpenAI uyumlu bir uç nokta olarak sunar; istekleri toplu işler (batching) ve önek önbelleği ile tekrarlanan yönerge metnini yeniden hesaplamaz.

Katman	Seçim	Neden bu seçim
Ajan çerçevesi	LangGraph 1.2.6	Adımları ve koşullu dallanmayı yönetir. Düz bir boru hattı kütüphanesi yerine graf seçilmesinin sebebi, akışın duruma göre farklı yollar izlemesidir.
Arayüz	Gradio 6.19.0	Operatör konsolu. Dış yazı tipi veya CDN kullanılmaz; tamamen çevrimdışı açılır.
Video okuma	PyAV 17.1.0	Zaman damgalı kare çıkarma. Kare çıkarma toplam sürenin yalnızca %2'sini alır (performans.log:12).
Yardımcı algı	Ultralytics YOLO 8.4.72 (yolo11n, yolo11n-pose)	Kişi/araç sayımı ve düşme pozu doğrulaması gibi kesin, sayısal ölçümler. Çoğu yolu varsayılan kapalıdır — gerekçesi bölüm 7'de.
Şema ve ayar	pydantic 2.13.4 · pydantic-settings 2.14.2	Çıktı sözleşmesini tip düzeyinde zorlar; ayarlar tek merkezden (DILAJAN_ ön ekli ortam değişkenleri) yönetilir.
Çalışma ortamı	Python 3.12.3 · Ubuntu 24.04.4 (WSL2) · RTX 5090 Laptop, 24.463 MiB	Tek dizüstü GPU üzerinde tam yerel çalışma hedefi. Sürücü 610.62; çekirdek 6.6.114.1-microsoft-standard-WSL2.

Not (dürüstlük). ultralytics paketi sanal ortamda kurulu olmasına rağmen ne requirements.txt ne de requirements-lock.txt içinde geçmektedir. Temiz bir kurulumda varsayılan açık olan poz doğrulaması çalışmazdı; hata toleransı sayesinde sistem çökmez, "karar veremedim" der. Bu bir bağımlılık belgeleme eksikliğidir ve kapatılacaktır.


vLLM sunucusu hangi bayraklarla açılıyor?

Kaynak: serve_vllm.py:25-56. Sabit bayraklar her koşuda aynıdır; koşullu bayraklar ayarlardan türetilir.

Bayrak	Değer	Ne işe yarar
--max-model-len	8192	Bir istekte modele verilebilecek azami belirteç (token) sayısı. Kare sayısı ve çözünürlük bu bütçeyle sınırlıdır.
--gpu-memory-utilization	0.90	Kartın %90'ı vLLM'e ayrılır; kalan pay diğer süreçler ve YOLO içindir.
--dtype	bfloat16	Hesap duyarlılığı.
--limit-mm-per-prompt	image: 16, video: 1	Bir yönergeye en çok 16 görüntü girebilir; segment başına 12 kare bu tavanın altındadır.
--enable-prefix-caching	açık	Yönergenin değişmeyen ön kısmı yeniden hesaplanmaz.
--max-num-seqs	32	Aynı anda işlenebilecek dizi sayısı tavanı.

4. Mimari genel bakış

Sistem bir ajandır: video, birbirini izleyen düğümlerden geçer ve her düğüm bir sonrakine bilgi aktarır. Düğümler ve aralarındaki kenarlar LangGraph ile kurulur (`build_graph()`, `graph.py:1497-1522`). Toplam 7 düğüm ve 1 koşullu kenar vardır.



Diyagramdaki turuncu kutu koşulludur: her koşuda çalışmaz. Bu, mimarinin en belirleyici özelliğidir — akış düz bir boru hattı değildir, ajan durumuna göre farklı yol izler. Yönlendirme kararını `route_after_perceive` (`graph.py:850-858`) verir.

Kod okuma bulgusu — belgelenmesi gereken bir ayrıntı

Yönlendirici fonksiyon iki değer döndürür: "reexamine" ve "reason". Ancak eşleşme tablosunda (`graph.py:1515-1516`) "reason" dizesi policy_gate'e bağlanmıştır. Yani perceive'den doğrudan reason'a geçiş yoktur; iki kol da policy_gate'te birleşir. Fonksiyonun kendi açıklama satırı hâlâ "doğrudan reason" demektedir — davranış ile açıklama metni arasında bir tutarsızlık vardır, davranış yukarıdaki diyagramdaki gibidir.

Düğümler arasında ne taşınıyor?

Düğümler birbirine doğrudan çağrı yapmaz; ortak bir durum nesnesi üzerinden haberleşir (AgentState, dilajan/agent/state.py). Bir düğüm yalnızca kendi ürettiği alanları döndürür, gerisi olduğu gibi akar.

Kanal	Kim yazar	Ne taşır
segments, video_info, scene_cuts	ingest	Segmentler, video süresi/çözünürlüğü, sert sahne kesimleri
events	perceive, reexamine, policy_gate	Olay listesi (zaman, açıklama, önem, kategori, konum)
reexamined	reexamine	Döngü muhafızı — ikinci tur yeniden inceleme olamaz
policy_escalations, policy_max_intrinsic	policy_gate	Kural yükseltmeleri ve yükseltme olmasaydı oluşacak en yüksek önem
summary, risk, actions, query_answer	reason	Özet, risk, aksiyonlar, sorgu yanıtı
triggered_functions, action_log	act	Çağrılan fonksiyonlar ve çağrı kaydı
trace	yedi düğümün hepsi	Karar günlüğü — operatörün okuduğu adım adım gerekçe
result	finalize	Nihai AnalysisResult nesnesi

Neden bu ayrıntı önemli? LangGraph, durum şemasında tanımlı olmayan anahtarları sessizce düşürür. Sorgu yanıtı özelliği eklenirken query_answer alanı bu yüzden şemaya gerçek bir kanal olarak eklenmiştir (state.py:32-36); aksi hâlde reason'ın ürettiği yanıt finalize'a hiç ulaşmazdı.

5. Düğüm düğüm anlatım

Bu bölüm sistemin kalbidir. Her düğüm için üç soruyu sırayla yanıtlıyoruz: ne yapar, neden var, hata olursa ne olur.

5.1 · ingest — görüntü alımı

Ne yapar. Videoyu PyAV ile açar ve zaman damgalı kareler çıkarır (extract_timestamped_frames, video.py:92). Kareleri 10 saniyelik segmentlere böler ve sert sahne kesimlerini arar.

Ayar	Varsayılan	Anlamı
segment_seconds	10,0 sn	Bir segmentin uzunluğu
fps_sample	2,0	Saniyede kaç kare örneklenir
max_frames_per_segment	12	Bir segmentten modele en çok kaç kare gider
frame_max_side / frame_min_side	768 / 640	Karenin ölçekleneceği piksel sınırları
scene_cut_threshold	0,30	Bu eşiğin üstündeki değişim "sahne kesimi" sayılır

Neden var. Modelin bağlam bütçesi sınırlıdır: 8192 belirteç. Bütün videoyu tek seferde vermek mümkün değildir. Segmentlere bölmek üç şey kazandırır: (1) her segment bütçeye sığar, (2) segmentler paralel işlenebilir, (3) olayların zaman damgası segment sınırlarından türetilir.

Sahne kesimi neden aranıyor? Bazı kayıtlar birbirinden bağımsız bölümlerin arka arkaya eklenmesiyle oluşur. Kesim bulunursa karar aşamasına "bu video çok bölümlüdür, bölümler arasında neden-sonuç kurma" uyarısı iletilir; böylece sistem alakasız iki sahneyi tek bir olay örgüsüne bağlamaz.

Hata olursa. Video okunamazsa akış durmaz: boş segment listesiyle devam eder ve karar günlüğüne "video okunamadı" satırı düşer (graph.py:310-312).

Bir kısayol. Canlı akış yolunda kareler zaten hazır; bu durumda ingest videoyu yeniden çözmez, hazır kareleri doğrudan kullanır (graph.py:299-306). Buna "bir kez çöz" yolu diyoruz.

5.2 · perceive — olay algısı (iki aşamalı)

Ne yapar. Her segmenti modele iki ayrı çağrıda sorar. Segmentler birbirinden bağımsız olduğu için aynı anda en çok 6 segment paralel işlenir (max_parallel_segments = 6).

	1. AŞAMA — serbest tarif	2. AŞAMA — olay çıkarımı
Girdi	Segmentin kareleri (görüntülü çağrı)	1. aşamanın ürettiği Türkçe metin (görüntüsüz çağrı)
Yönerge	SEGMENT_DESCRIBE_INSTRUCTION (prompts.py:49)	EVENT_EXTRACTION_INSTRUCTION (prompts.py:97)
İstenen	Ortamı ve olağan durumu belirle, sonra gördüğünü serbest Türkçe anlat	Bu tarifi yapılandırılmış olay listesine çevir
Ayarlar	sıcaklık 0,2 · en çok 400 belirteç · tekrar cezası 1,15	sıcaklık 0,1 · en çok 400 belirteç

Serbest tarife hangi katmanlar ekleniyor? Yönerge sabit değildir; açık olan özelliklere göre sırayla katman eklenir (graph.py:569-590):

- Tesis kuralları — operatör metin girmişse (varsayılan boş).
- Dedektör kanıtı — YOLO nesne sayıları (varsayılan kapalı; gerekçesi bölüm 7).

- Tehdit yorumu katmanı — güvenlik analisti bakış açısı (varsayılan açık).
- Hareket belirginliği ipucu — karelerdeki hareketin nerede yoğunlaştığı (varsayılan açık).
- Sorgu odağı bloğu — operatörün serbest metin sorgusu; bilinçli olarak en sona eklenir (bölüm 7-e).

Neden doğrudan JSON istemiyoruz? (bu tasarımın en önemli kararı)

Kodda yazılı gerekçe (prompts.py:47-48) şudur: katı JSON yönergesi, düşük çözünürlüklü gerçek görüntüde modeli aşırı temkinli yapıyor. Model aynı anda hem "ne görüyorum" hem "hangi alana ne yazmalıyım" sorularıyla uğraşınca, emin olmadığı her ayrıntıyı atlıyor ve olay listesi boşalıyor. Serbest tarif modelin tam algısını ortaya çıkarır; yapılandırma işini ikinci, görüntüsüz ve ucuz bir çağrıya bırakırız. Ek kazanç: iki aşama arasına doğrulama katmanları sokabiliyoruz.

2. aşamadan sonra çalışan süzgeçler

Olaylar üretildikten sonra, aynı düğüm içinde sırayla şu süzgeçlerden geçer. Hepsinin ortak ilkesi aynıdır: bir süzgeç olayı silmez, yalnızca önem derecesini düşürür.

Süzgeç	Varsayılan	Ne yapar
Öz-doğrulama	AÇIK	Yüksek ve üzeri önemdeki olaylar için modele "bunu gerçekten gördün mü" diye sorulur. Doğrulanmayan olay silinmez, önemi Orta'ya düşer (graph.py:606-616).
Poz doğrulama	AÇIK	Düşme iddiası varsa YOLO poz modeliyle gövde açısı ölçülür. Yalnızca kesin "REDDET" kararında önem Orta'ya çekilir; kararsızlıkta modelin sözü geçerlidir.
Mekânsal dayanaklandırma	AÇIK	Yüksek ve üzeri olaylara sınırlayıcı kutu (bbox) ve 3×3 ızgarada konum ("üst sol", "merkez") eklenir. Kanıt paketindeki işaretli kareler buradan gelir.
Semantik olabilirlik	kapalı	Kişi-merkezli bir olay iddia edildiği hâlde karede kişi yoksa önem düşürülür.
Yasak bölge / araç / kalabalık	kapalı	Operatör 3×3 ızgarada bölge tanımlarsa ihlal olayı üretilir; araç ve toplanma/panik tespitleri de bu grupta.

Hata olursa. Tek bir segment çökse bile diğerleri işlenmeye devam eder (graph.py:716-717). Düğümün tamamı hata verse bile o ana kadar toplanan olaylar korunur ve karar günlüğüne not düşülür (graph.py:840-841).

Hızlı mod. Gecikmenin kritik olduğu durumlarda tarif ve çıkarım tek çağrıda birleştirilebilir (single_pass_perceive). Bu modda doğrulama ve dayanaklandırma çalışmaz; kalite karşılığında süre kazanılır. Varsayılan kapalıdır.

5.3 · reexamine — koşullu yeniden inceleme

Ne yapar. Yalnızca Orta önemdeki olaylara geri döner ve o olayın geçtiği segmentin karelerine tekrar bakar. Modele tek bir soru sorulur (graph.py:861-865) ve tek kelime yanıt istenir:

"Bu güvenlik kamerası karelerinde şu gözlem var: "{event}". Bu GERÇEKTEN dikkate değer/anormal bir olay mı, yoksa olağan/rutin bir aktivite mi? Yalnızca TEK KELİME yanıt ver: CİDDİ (gerçek ciddi olay), RUTİN (olağan, olay değil), veya BELİRSİZ."

Yanıt	Sonuç
CİDDİ	Olayın önemi Yüksek'e çıkarılır.
RUTİN	Olayın önemi Düşük'e indirilir ve olay "rutin" listesine yazılır.
BELİRSİZ (veya tanımsız yanıt)	Olaya hiç dokunulmaz — mevcut hâliyle korunur.

Neden anahtar kelimeler Türkçe işaretli yazılmış? Yanıt .upper() ile büyütülüp "RUTİN" ve "CİDDİ" alt dizeleri aranır (graph.py:894-905). Türkçe "rutin" kelimesinin büyük hâli RUTİN olsaydı, noktalı İ ile noktasız I farklı karakterler olduğu için eşleşme tutmazdı. İşaretsiz yazım burada bilinçli ve işlevseldir — 13.5'teki büyük-İ kusurunun aynısının bu yolda oluşmasını engeller.

Ne zaman tetiklenir. Üç koşul birlikte sağlanmalıdır: özellik açık olmalı (varsayılan açıktır), bu koşuda daha önce yeniden inceleme yapılmamış olmalı ve olaylardan en az birinin önemi tam olarak Orta olmalıdır. Yüksek veya Düşük olaylar tetiklemez.

Neden var. "Orta" sistemin kararsızım dediği yerdir. Bu olayları olduğu gibi bırakmak iki hataya birden yol açar: gerçek olaylar gözden kaçır, olağan hareketler gereksiz uyarı üretir. Yeniden inceleme, kararsız durumları ikinci bir görsel bakışla ayırır. Bu, ajanın adaptif otonomi özelliğidir: sistem işin zorluğuna göre kendi kendine daha fazla hesap harcamaya karar verir.

Sonsuz döngü riski nasıl kesiliyor? Düğüm çalıştığında duruma reexamined = True yazar (graph.py:913, 916). Yönlendirici bu bayrağı gördüğü an ikinci turu reddeder. Yeniden inceleme bir koşuda en çok bir kez çalışır.

Hata olursa. Tek bir olayın çağrısı başarısız olursa o olay değiştirilmeden korunur; düğümün tamamı hata verirse olay listesine hiç dokunulmadan devam edilir (graph.py:911-914). Yani hata hâlinde sistem hiçbir önem derecesini oynatmaz.

5.4 · policy_gate — tesis kuralı hakemliği

Ne yapar. Operatörün satır satır yazdığı tesis kurallarını olaylarla eşleştirir. Kural satırının biçimi şudur (policy.py:170):

<ihlal tanımı> | <uygun görünüm> | Düşük|Orta|Yüksek|Kritik | sevk

Eşleşme bulunursa olayın önemi, operatörün beyan ettiği seviyeye tek yönlü yükseltilir — hiçbir kural bir olayın önemini düşüremez. Video başına yalnızca tek ve görüntüsüz bir model çağrısı yapılır.

Neden bu sırada? Kod içindeki gerekçe (graph.py:1511-1514) üç madde sayar: (1) reexamine "Orta" olayları aşağı çekebildiği için hakemlik ondan sonra çalışmalıdır, aksi hâlde yükseltme geri alınır ve zaten rutin bulunmuş bir olay sessizce yükseltilebilirdi; (2) yinelenen olaylar temizlendikten sonra aday sayısı küçüktür, tek çağrı yeter; (3) policy_gate mutasyon zincirinin sonudur.

Varsayılan davranış: hiçbir şey. Tesis kuralı girilmemişse düğüm ilk satırında çıkar (graph.py:941-942): model çağrılmaz, karar günlüğüne satır bile eklenmez. Bu, "varsayılan kapalı" ilkesinin (bölüm 7-d) somut bir örneğidir.

Hata olursa. Düşüm hata verirse olaylar değiştirilmeden döner (graph.py:990-992); yani sistem kural yokmuş gibi davranır.

5.5 · reason — değerlendirme

Ne yapar. Bütün olay listesini tek seferde modele verir ve üç şey ister: özet, gerekçeli risk seviyesi, aksiyon önerileri. Çağrı görüntüsüzdür; sıcaklık 0,2 ve en çok 800 belirteçtir (graph.py:1028).

Neden ayrı bir düşüm? Algı ile yargı ayrılmalıdır. perceive "ne gördüm" der, reason "bu ne anlama geliyor" der. Bu ayrım sayesinde algı katmanını değiştirmeden karar politikasını değiştirebiliyoruz.

Modelin çıktısı olduğu gibi kabul edilmez; üzerine koruma kuralları uygulanır:

Koruma kuralı	Ne yapar	Neden
Risk tabanı	Risk seviyesi, en yüksek olay öneminden düşük olamaz; düşükse yükseltilir ve günlüğe yazılır.	Model "Kritik bir olay var" deyip riski Orta yazamaz.
Politika sevk maskesi	Risk eşiği yalnızca kural yükseltmesiyle aşıldıysa risk operatöre Yüksek gösterilir ama otomatik sevk sinyali maskelenir.	Bu maske olmasaydı "kural yükseltmesi sevk açmaz" uyarı yalan olurdu; risk tabanı önemi riske taşıyıp kapıyı arka kapıdan açardı.
Teyit-sonra-aksiyon	Her yükseltilmiş kural için tek bir aksiyon üretilir: "operatör teyidi sonrası ekip sevk".	Kural kaynaklı yükseltme insan onayına bağlanır.
Algı güveni	Görüntünün kısa kenarı 360 pikselin altındaysa "manuel teyit önerilir" aksiyonu eklenir.	Düşük çözünürlük ölçülmüş bir zayıflıktır (bölüm 14); sistem bunu kendisi beyan eder.
Dil saflığı	Çıktıda Latin dışı yazı sistemi (Çince, Kiril, Arap vb.) tespit edilirse metin düzeltilir.	Çıktının tamamı Türkçe olmalıdır.

Hata olursa. Model çağrısı veya JSON ayrıştırması çökerse yerel varsayılanlar korunur: özet "Özet üretilemedi.", risk Orta / "Belirlenemedi." (graph.py:1023-1024, 1046-1047). Akış durmaz.

5.6 · act — sevk kapısı

Ne yapar. Operasyonel fonksiyonların çağrılıp çağrılmayacağına karar verir. Karar tek bir mantıksal ifadedir (graph.py:1406-1411) ve üç terimin "veya"sıdır:

Terim	Koşul	Anlamı
1 — Modelin kendi yargısı	Politika yükseltmesi hiç olmasaydı oluşacak en yüksek olay önemi $\geq$ Yüksek	Sevk yalnızca modelin görüntüye dayalı kendi yargısıyla açılabilir. Operatörün beyanı bu terimi etkilemez.
2 — Yetkilendirilmiş kural	Kural satırında sevk yetkisi verilmiş ve <code>policy_dispatch</code> açık ve olay önemi $\geq$ Yüksek	İki ayrı onay birlikte gerekir: kural satırındaki yetki ve sistem ayarı.
3 — Risk eşiği	Risk $\geq$ Yüksek, ancak geri-çağırma eğilimi kapalıysa ve risk yalnızca kural yükseltmesinden gelmiyorsa	İki maskeleye, riskin arka kapıdan sevk açmasını engeller.

Boş politikada ne olur? Hiç kural yoksa ifade cebirsel olarak şuna indirgenir (graph.py:1395-1398, birim testiyle doğrulanır): en yüksek olay önemi $\geq$ Yüksek VEYA risk $\geq$ Yüksek. Yani varsayılan kurulumda kapı sade ve öngörülebilirdir.

Kapı açıksa model hangi fonksiyonların çağrılacağına karar verir. Çağrılar körü körüne çalıştırılmaz: bilinmeyen fonksiyon adı en yakın gerçek ada çözülür, eksik veya sapmış argümanlar olay bağlamından onarılır (graph.py:1232, 1302). Kullanılabilir altı fonksiyon: `saglik_ekibi_yonlendir`, `guvenlik_ekibi_uyar`, `alan_guvenligini_sagla`, `acil_durdurma_tetikle`, `olay_kaydi_olustur`, `yonetici_bilgilendir` (mock_functions.py:226-233).

Kapı kapalıysa boş liste döner ve — eğer kural yükseltmesi olmuşsa — karar günlüğüne "sevk yolu kapalı" satırı, sebebiyle birlikte yazılır. Operatör neyin neden olmadığını görür.

Hata olursa. Aksiyon seçimi çökerse o ana kadarki çağrı kaydıyla devam edilir (graph.py:1451-1452).

5.7 · finalize — raporlama

Ne yapar. Bütün kanalları tek bir `AnalysisResult` nesnesinde birleştirir: özet, olaylar, risk, aksiyonlar, video süresi, tetiklenen fonksiyonlar, çağrı kaydı, karar günlüğü ve varsa sorgu yanıtı.

Neden ayrı bir düğüm ve neden iki kademeli koruma? Kodda yazılı gerekçe (graph.py:1461-1462) nettir: `result` alanını döndürmemek, çağırın tarafı `KeyError` ile çökertirdi. Bu yüzden finalize iki kademeli güvenli varsayılanla sahiptir: birinci kademede Orta riskli "Sonuç birleştirilemedi; operatör manuel teyidi önerilir." sonucu üretilir; o da çökerse en küçük geçerli sonuç nesnesi döner. finalize her koşulda bir sonuç döndürür.

Hata toleransının bütünü

Yedi düğümün hepsinin dış gövdesi hata yakalayıcıyla sarılıdır (graph.py:25-27). İlke şudur: bir adım çökerse akış durmaz; karar günlüğüne not düşülür ve güvenli varsayılanla devam edilir. Yardımcı katmanlarda da aynı desen vardır — dedektörün her fonksiyonu hata hâlinde "olay üretme" anlamına gelen boş sonuç döndürür.

Tek istisna: fail-closed bir seçenek

Yalnızca `policy_verify_frames` ayarı tersine çalışır: kural yükseltmesini karşıtsal görsel teyide bağlar ve teyit alınamazsa yükseltmeyi reddeder. Yanlış-pozitif ve gecikme profili ölçülmediği için varsayılan kapalıdır (config.py:165-166). Ölçülmemiş bir şeyi varsayılan yapmıyoruz.

6. Kritik tasarım kararları

Bu bölümdeki her karar aynı üç başlıkla anlatılır: ne yaptık, neden, ölçülen sonuç. Ölçülemeyen yerlerde bunu açıkça yazıyoruz.

6.a · İki aşamalı algı

Ne yaptık	Segmenti modele iki kez sorduk: önce serbest Türkçe betimleme (görüntülü), sonra o betimlemeden olay çıkarımı (görüntüsüz).
Neden	Kodda yazılı gerekçe: katı JSON yönergesi düşük çözünürlüklü gerçek görüntüde modeli aşırı temkinli yapıyor ve olay listesi boşalıyor (prompts.py:47-48). Serbest tarif modelin tam algısını ortaya çıkarır; yapılandırmayı ayrı ve ucuz bir çağrıya bırakırız.
Ölçülen sonuç	İki aşamalı akış üretim yapılandırmasıdır ve bütün ölçümler bu yapılandırmayla alınmıştır. Tek-geçişli alternatif (single_pass_perceive) hızlı mod için korunmuştur; kodda kayıtlı beklentisi gecikmenin yaklaşık yarıya inmesidir (prompts.py:130-132). İki akışın doğruluk farkı ayrı bir A/B ile ölçülmemiştir.

6.b · Koşullu yeniden inceleme (adaptif otonomi)

Ne yaptık	Yalnızca "Orta" önemli olay varsa çalışan bir düğüm ekledik; ajan o segmentin karelerine ikinci kez bakıp olayı yükseltir, düşürür ya da olduğu gibi bırakır.
Neden	Sabit boru hattı her videoya aynı hesabı harcar. Kararsızlık yoksa ikinci bakış israftır; kararsızlık varsa ilk bakış yetersizdir. Ajanın işin zorluğuna göre kendi kendine karar vermesi, bu projeyi bir betikten ajana dönüştüren özelliktir.
Ölçülen sonuç	Mekanizma ölçüm koşullarında aktiftir ve karar günlüğüne kaç olayın yükseldiğini/düşürüldüğünü yazar. Açık/kapalı A/B'si ayrıca ölçülmemiştir — bu belgede sayı verilmemektedir.

6.c · Sevk kapısı — yanlış alarmı nasıl kestik

Ne yaptık	Operasyonel fonksiyonları riskten değil, modelin kendi görsel yargısından tetikledik. Operatör beyanıyla oluşan yükseltmeler için iki ayrı onay (kural satırındaki yetki + sistem ayarı) şartı koyduk ve riskin arka kapıdan kapıyı açmasını maskelerle engelledik.
Neden	Yanlış ekip çağırmak, kaçırılan bir olaydan farklı ve daha pahalı bir hatadır: güven kaybettirir ve gerçek çağrılarının ciddiye alınmamasına yol açar. Bu yüzden tespit eşiğiyle sevk eşiğini ayırdık.
Ölçülen sonuç	Normal kliplerde yanlış operasyonel tetik: holdout 0/8 (eval_20260728_193430.json) ve senaryo 0/12 (eval_20260728_194508.json). Adlandırma A/B'sinde A ve B kollarında 0/8, C kolunda 1/8 (naming_ab_*.json). Savunma setinde ise kurallar kapalıyken 4/100, açıkken 8/100 (eval_20260726_162613.json / _171601.json). Dürüst okuma: 0/8 gözlemi "%0" demek değildir; gerçek oran Wilson üst sınırına kadar çıkabilir.

6.d · Varsayılan-kapalı ilkesi

Ne yaptık	Her yeni özellik kapalı doğar. Açılabilmesi için ölçümle kanıt gerekir. Bugün varsayılan açık olan bayraklar yalnızca şunlardır: önek önbellesi, algı güveni, tehdit yorumu, hareket ipucu, poz doğrulama, olay doğrulama, mekânsal dayanaklandırma, adaptif yeniden inceleme. Diğerlerinin hepsi kapalı ya da boştur.
Neden	İki sebep. Birincisi bilimsel: ölçülmemiş bir özelliğin varsayılan olması, sonraki bütün ölçümleri kirlendir. İkincisi pratik: özellik kapalıyken yönerge metinlerine tek karakter eklenmez, böylece eski ölçümler bit düzeyinde yeniden üretilebilir. Sorgu özelliği eklenirken bu, 11 yönerge metninin SHA-256 özetiyle doğrulanmıştır.
Ölçülen sonuç	Elenen yolların çoğu (bölüm 13) tam olarak bu disiplin sayesinde yakalandı: YOLO kanıt enjeksiyonu, CLAHE, ipucu listesi ve risk eğilimi ölçülüp geri alındı, varsayıllana yerleşmedi.

6.e · Sorgu-güdümlü analiz: "sorgu odaklar, filtrelemez"

Operatör analiz kutusuna serbest metin yazabilir ("forklift hareketlerine bak"). Bu metin iki yerde kullanılır: algı aşamasında odak olarak, karar aşamasında ek bir yanıt alanı olarak. Sorgunun olay listesini filtrelediği tek bir kod satırı yoktur.

Ne yaptık	Sorguyu yönergenin en sonuna ekledik ve iki güvence yazdık: "odak konusuyla ilgisiz olsa bile yangın, duman, patlama, silah, ciddi kaza, kavga, yere düşmüş kişi gibi kritik durumları HER ZAMAN raporla" (prompts.py:177-181) ve "sorgu yalnızca ek bir yanıt alanıdır, bir filtre değildir" (prompts.py:225-226).
Neden en sona?	İki gerekçe kodda yazılıdır (graph.py:583-589): (1) saf ek — sorgu boşken yönerge bit düzeyinde eskisiyle aynı kalır; (2) yakınlık etkisi — modelin okuduğu son talimat "kritik durumları her zaman raporla" olur.
Güvenlik	Sorgu metni bir talimat değil veri olarak işlenir: <, >, { ve } karakterleri temizlenir, bütün boşluklar tek boşluğa iner (çok satırlı sahte sistem mesajı kalıbı kırılır), 500 karakterde kırpılır ve sınırlayıcılar arasına yerleştirilir. Yanıt uzunluğu 1200 karakterle sınırlıdır. Sorgu yanıtı çıktı sözleşmesine sızmaz.
Ölçülen sonuç	Gerçek modelle A/B yapıldı (bölüm 12.2). En kötü durum seçildi: hiç forklift içermeyen bir sette "sadece forklift hareketlerine bak, başka hiçbir şeyle ilgilenme" sorgusu. Yangın tespiti üç koşuda da 10/10 kaldı; anomali tespiti üç koşuda da %96 kaldı.

7. Yardımcı algı katmanı — YOLO

Görsel-dil modeli "kalabalık var" der ama kaç kişi olduğunu güvenilir saymaz. YOLO ise sayar. Bu yüzden sisteme küçük bir nesne/poz dedektörü eklenmiştir: `yolo11n.pt` (5.613.764 bayt) ve `yolo11n-pose.pt` (6.255.593 bayt), her ikisi de GPU üzerinde çalışır (`detector.py:30, :84`). Amaç modeli değiştirmek değil, heterojen bir ikinci görüş eklemektir.

Dedektör yolu	Durum	Neden bu durumda
Poz ile düşme doğrulama <code>detector.py:88</code>	AÇIK	Düşme, ölçülebilir bir geometridir: omuz ve kalça noktalarından gövde açısı hesaplanır. Açı 30°'nin altındaysa dik, 50°'nin üstündeyse yatay oyu verilir; arası sayılmaz. Yeterli oy yoksa "kararsızım" der. Yalnızca kesin reddetme kararında önem düşürülür — yani dedektör olay silemez.
Nesne listesi enjeksiyonu <code>detector.py:34</code>	KAPALI	Ölçülüp geri alındı. Ham nesne sayılarını ("kişi×9, araba×6") yönergeye eklemek en kritik metrikte gerileme yarattı: normal kliplerde yanlış-pozitif %0'dan %12'ye çıktı, kategori adlandırma %25'ten %21'e, risk kalibrasyonu %46'dan %29'a düştü (iyileştirmeler.md:73-80).
Kişi varlığı kontrolü <code>detector.py:58</code>	kapalı	Grenli görüntüde YOLO'nun kişi tespiti güvenilirmez; yanlış eleme geri-çağırma riski yaratır. İsteğe bağlıya düşürüldü.
Yasak bölge ihlali <code>detector.py:162</code>	kapalı	Operatör 3×3 ızgarada bölge tanımlamadan anlamsızdır; tanımlanınca açılır.
Araç ihlali <code>detector.py:196</code>	kapalı	Tesise özgüdür; isteğe bağlı.
Kalabalık istatistiği <code>detector.py:243</code>	kapalı	Toplanma ve ani dağılma tespiti; isteğe bağlı (eşik: en az 5 kişi).

Buradan çıkan ders — belgenin en öğretici bulgularından biri

Dedektör sahneleri gerçekten ayırıyordu (anomali sahneleri yoğun, normal sahneler seyrek). Buna rağmen ham sayıyı yönergeye enjekte etmek zarar verdi: model kalabalığı tehdit sanmaya başladı. Doğru olan sinyal, yanlış olan sunum biçimiydi. Bu yüzden bugün yalnızca tek bir dedektör yolu açıktır ve o da ham sayı değil, geometrik bir yargı (düştü mü, düşmedi mi) üretir.

Kapsam notu. Depoda deterministik bir kamera sabotaj tespiti de bulunur (donma, karartma, örtme — `dilajan/tamper.py`). Bu modül ana ajan akışının parçası değildir; yalnızca canlı akış betiğinde çağrılır (`scripts/live_analyze.py:111`). Bunu "pipeline'da var" diye sunmak yanlış olur.

8. Çıktı sözleşmesi

Şartnamenin istediği JSON tam olarak dört anahtar içerir. Bu sözleşme bozulamaz ve beş ayrı test dosyasıyla doğrulanır (`schema.py:93-105`).

```
{
  "summary": "Depoda yangın başlangıcı gözlemlendi; duman hızla yayılıyor.",
  "events": [
    {"time": "00:12", "event": "Makine yanında alev ve duman"},
    {"time": "00:24", "event": "Personel alanı terk ediyor"}
  ],
  "risk": "Kritik",
  "actions": ["Güvenlik ekibini uyar", "Alanı güvenlik altına al"]
}
```

Neden değişmez? Çünkü sözleşme bir arayüz taahhüdüdür. Yeni bir özellik eklendiğinde çıktıya alan eklemek en kolay yoldur, ama bunu yapan her sistem entegrasyonu bozar. Bu yüzden zenginleştirmeler ayrı bir kanalda tutulur.

Sözleşme (4 anahtar)	Zengin çıktıda ek olarak bulunanlar
summary — metin events — yalnızca time ve event risk — tek kelime actions — metin listesi	events içinde ayrıca: önem, kategori, bitiş zamanı, sınırlayıcı kutu, 3×3 bölge risk nesnesinde gerekçe actions içinde öncelik ve gerekçe video_duration, triggered_functions, action_log, decision_trace, query_answer

Önem dereceleri dört kademelidir (Düşük, Orta, Yüksek, Kritik); kategoriler yedi tanedir (Normal, Güvenlik, Kaza, Sağlık, Anomali, Yetkisiz Erişim, Diğer). Bunlardan dördü "tehlike" alt kümesini oluşturur ve koruma kurallarında kullanılır.

9. Operatör arayüzü

Arayüz bir tasarım taslağı değil, çalışan bir konsoldur (app.py, 778 satır). Karanlık temalı, dış yazı tipi veya CDN kullanmayan, tamamen çevrimdışı açılan bir Gradio uygulamasıdır.

Panel	Ne gösterir / ne işe yarar
Sunucu durum rozeti	Yerel model sunucusunun ayakta olup olmadığı.
Görüntü girişi	Video yükleme. Yüklene dosya oynatılabilir biçime dönüştürülür.
Savunma / tesis ayarları	Katlanır panel, kapalı başlar: tesis kuralları metni, 3×3 ızgarada yasak bölgeler, kalabalık ve araç seçenekleri.
Analiz sorgusu	Serbest metin kutusu. Yanında "sorgu odaklar, filtrelemez" uyarısı yazılıdır.
Ajan durumu (canlı akış)	Hangi düğümün çalıştığını adım adım gösteren gösterge; yeniden inceleme atlanırsa "atlandı" olarak işaretlenir.
Risk değerlendirmesi	Renk kodlu risk rozeti ve gerekçesi.
Sorgu yanıtı kartı	Yalnızca sorgu girildiyse görünür; sorgu boşken tamamen gizlidir.
Operasyon özeti	Türkçe özet metni.
Olay zaman çizelgesi	Olayların videonun neresinde olduğunu gösteren şerit.
Tespit edilen olaylar	Tablo: Zaman · Olay · Önem · Kategori · Konum.
Aksiyon önerileri / tetiklenen fonksiyonlar	İki ayrı liste — öneri ile fiilî çağrı birbirine karıştırılmaz.
Operatör asistanı	Analiz bağlamına dayalı, çok turlu sohbet paneli. Operatör "ikinci olayı açıkla" diyebilir.
Sekme: Ajan karar günlüğü	Sistemin adım adım neden o kararı verdiği.
Sekme: Ham JSON	Zengin çıktının tamamı.
Sekme: Olay tutanağı ve kanıt paketi	Resmî Türkçe tutanak (model kullanmadan, deterministik üretilir) ve sınırlayıcı kutu çizilmiş anahtar kareler + SHA-256'lı manifest.
Sekme: Vardiya devir-teslim brifingi	Seçilen saat penceresindeki oturumları tek bir doğal Türkçe brifinge indirir.

Bulgu (dürüstlük). Arayüzdeki adım göstergesi altı adım listeler; grafta ise yedi düğüm vardır — `policy_gate` göstergede yoktur (app.py:41-48). Bunun bilinçli bir sadeleştirme mi yoksa eksik mi olduğu koddan yazılı değildir; kapatılacak bir açıktır.

Eş zamanlılık: iki operatör aynı anda analiz başlatırsa?

Bu, gerçekten yaşanmış ve çözülmüş bir hatadır. Arayüz her istekte tesis kurallarını modül düzeyindeki genel ayar nesnesine yazıyordu. İki eş zamanlı analizde A isteğinin kuralları B'nin analizine sızıyordu; değerler analiz bitince temizlenmediği için sonraki isteğe de taşınıyordu (config.py:236-241).

Neden bağlam değişkeni (contextvar) kullanılmadı? Çünkü perceive segmentleri işçi iş parçacıklarında paralel işliyor ve ayarları o iş parçacıklarında okuyor. Bağlam değişkenleri işçi iş parçacıklarına otomatik taşınmaz; operatörün kuralları sessizce düşerdi (config.py:242-250).

Seçilen çözüm. Genel değişiklik bir kapıyla korunur ve eski değerler her durumda geri yüklenir. Kapı için Lock değil BoundedSemaphore kullanılır: analiz fonksiyonu bir üretectir ve Gradio üretecin ardışık adımlarını farklı iş parçacıklarında çalıştırabilir; kilit sahiplik bağlıdır ve başka iş parçacığından bırakılırsa hata verir, semaforun sahiplik kavramı yoktur (config.py:258-262).

10. Veri — hangi setler, kaç klip, nereden

Aşağıdaki klip sayıları bu koşumda dosya sistemi taranarak sayılmıştır.

Set	Klip	İçerik	Köken ve neden bu set
eval_holdout	32	8 anomali kategorisi × 3 + 8 Normal	UCF-Crime. Ayrılmış doğrulama seti: ayar/geliştirme bu sette yapılmaz. eval_tune ile kesişimi ölçüldü: 0.
eval_tune	31	24 anomali + 7 Normal	UCF-Crime. Ayar ve geliştirme seti — holdout'a dokunmadan denemek için.
eval_scenario	37	Düşme 15 + Yangın 10 + Normal 12	Yangın kısmı FIRESENSE (CC BY 4.0), düşme kısmı GMDCSA-24 ve URFD. Senaryo odaklı: şartnamenin örneklediği olay tiplerine yakın. Dizinde ayrıca _deprecated_frozen_fall/ altında 9 klip görünür; bunlar donmuş kareden oluştuğu için karantinaya alınmıştır ve ölçüme girmez (alt çizgiyle başlayan klasörler eval_clips.py tarafından atlanır). Dizini elle sayan 46 dosya görür, ölçülen 37'dir.
eval_defense	200	100 anomali + 100 Normal, tamamı 1080p	Mendeley "Video Dataset for Safe and Unsafe Behaviours" — Eskişehir OSB üretim tesisi, iki IP kamera. Hedef alan: tesise özgü kural ihlali ölçümü buradadır. Tabakalı, sabit tohumlu örnekleme.
eval_stress	9	Yangın renkli çetin negatifler	FIRESENSE. Karşıtsal set: gün batımı, kırmızı ışık gibi yangına benzeyen ama yangın olmayan sahneler.
robust	4	siyah · bozuk · boş · çok küçük video	Elle üretildi. Sistemin bozuk girdide çökmediğini göstermek için.
industrial	691	8 sınıf, 1080p, 24 fps	eval_defense'in örneklendiği havuz. Sınıf dağılımı kaynağın kendi API'siyle birebir doğrulandı.

Veri disiplini

- Ayrık bölme. eval_tune ile eval_holdout arasında MD5 kesişimi sıfırdır.
- Tekilleştirme koşu anında yapılır. Aynı içerik iki dosya adıyla duruyorsa bir kez sayılır. İncelenen bütün A/B koşullarında elenen klip sayısı 0.
- Sızıntı uyarısı otomatiktir. Bilinen sızıntılı bir set kullanılırsa sonuç dosyasına uyarı alanı yazılır. İncelenen sekiz koşu dosyasının hepsinde bu alan boştur — yani sızıntılı set kullanılmamıştır.
- Yanlış etiketli dört klip tespit edilip setlerden çıkarıldı ve ayrı bir karantina dizinine taşındı.

Veriyle ilgili en ciddi kusur: çözünürlük-etiket karışıklığı

eval_holdout ve eval_scenario setlerinde tek bir 1080p anomali klibi yoktur; buna karşılık normal kliplerin önemli bir kısmı 1080p'dir. Bu durumda modelin kararının ne kadarı olayın içeriğinden, ne kadarı görüntü kalitesi ipucundan geldiği ayrıştırılamaz. eval_defense seti (200 klibin tamamı 1080p) tam da bu yüzden kurulmuştur.

11. Ölçüm metodolojisi

Bu bölüm, sayıların nasıl üretildiğini anlatır. Projede ölçüm araçlarının kendisi de test edilmiştir — bu, ayırt edici bir noktadır.

11.1 · Neden Wilson güven aralığı?

Küçük örnekleme "24/25 = %96" ifadesi tek başına yanıltır. 25 klipte bir klibin farklı çıkması oranı %4 oynatır. Wilson güven aralığı, gözlenen orandan gerçek oranın hangi aralıkta olabileceğini verir. Örneğin 24/25 için aralık [%80-%99]'dur: yani gerçek başarı %80 kadar düşük de olabilir.

En önemli kullanımı sıfırlardadır. "Yanlış alarm %0" cümlesi bu projede yasaktır. 0/9 gözleminin Wilson üst sınırı %30'dur — yani dokuz denemede hiç hata görmemek, gerçek hata oranının %30 olmasıyla uyumludur. Bu yüzden bütün oranlar "k/n + aralık" biçiminde yazılır.

11.2 · Neden McNemar (eşli) testi?

İki yapılandırmayı karşılaştırırken aynı klipler her iki kolda da koşulur. Bu durumda bağımsız örneklem testleri yanlıştır. McNemar testi yalnızca fikir değiştiren klipleri sayar: yalnız A'nın doğru bildikleri (b) ve yalnız B'nin doğru bildikleri (c). İkisinin de doğru ya da ikisinin de yanlış bildiği klipler hiçbir kanıt taşımaz.

Küçük n'de yaklaşık formüller güvenilmez olduğu için tam (exact) binom testi kullanılır. Fark için Newcombe (1998) yöntemiyle güven aralığı, ayrıca güç analizi raporlanır — "anlamsız çıktı" ile "ölçecek gücümüz yoktu" farklı şeylerdir.

11.3 · Gürültü tabanı — neden aynı koşu iki kez aynı sonucu vermiyor?

Modele "rastgelelik yok" ayarı verilse bile (temperature = 0) iki koşu birebir aynı çıkmıyor. Sebep şudur: vLLM istekleri toplu işler. Aynı anda kaç isteğin işlendiği, kayan nokta toplamalarının sırasını değiştirir. Ortaya çıkan çok küçük sayısal farklar, iki kelimenin olasılığı birbirine yakınsa modelin farklı bir kelime seçmesine yeter. Bir kelime değişince cümle, cümle değişince olay listesi değişebilir.

Bunu ölçtük: aynı yapılandırmayı hiçbir şeyi değiştirmeden ikinci kez koşturduk (A ve A'). Bu koşulda ham satırlardan yeniden hesapladığım sonuç:

Karşılaştırma	Tespitte uyumsuzluk	Adlandırmada uyumsuzluk
A ile A' (aynı yapılandırma, iki koşu)	2/25 = %8	3/25 = %12
A ile B (farklı sorgu)	2/25 = %8 — aynı klipler	3/25 = %12 — aynı klipler
A' ile B	0/25	0/25

Bu tablonun anlamı

Yukarıdaki iki metrikte (tespit ve adlandırma) A ile B arasındaki bütün fark, A ile A' arasında da vardır — üstelik birebir aynı kliplerde. Yani bu iki metrikte sorguya atfedilebilecek ek uyumsuzluk sıfır kliptir. (Risk kalibrasyonu için aynı şey söylenemez; oradaki bir kliplik artık fark 12.2'de açıkça yazılmıştır.) Daha genel sonuç: $n \approx 25$ 'lik bir sette yapılan hiçbir A/B, tespitte %8'ten, adlandırmada %12'den küçük bir etkiyi gürültüden ayıramaz. Bu belgede raporlanan küçük farklar bu ölçekle okunmalıdır. (Not: adlandırma için %12'lik taban bu koşulda hesaplanmıştır; bazı depo belgeleri her iki metrik için de %8 kullanmaktadır — düzeltilmesi gereken bir noktadır.)

11.4 · Ölçüm dürüstlüğü ilkelerimiz

- Her oran k/n biçiminde ve güven aralığıyla yazılır; çıplak yüzde yasaktır.
- "%0" mutlak ifadesi kullanılmaz.
- n küçükken (≤ 48) sıralama veya "şu yöntem daha iyi" karşılaştırması yapılmaz.
- Dayanaklı metrikler (klibin bilinen etiketine karşı ölçülen) ile iç tutarlılık metrikleri (sistemin kendi çıktısına karşı ölçülen) asla tek skorda birleştirilmez.
- Eski ölçüm kuralı kasten bozuk bırakılmıştır ve düzeltilmeyecektir — eski sonuçların yeniden üretilebilmesi için. Yeni ve eski kural, sonuç dosyasına yan yana yazılır.

12. Ölçülen performans

Aşağıdaki bütün tablolar ham sonuç dosyalarından okunmuştur; dosya adları belirtilmiştir. Köşeli parantez içindekiler %95 Wilson güven aralığıdır.

12.1 · İki set, tam koşu (28 Temmuz 2026)

Ölçüm	eval_holdout (grenli, n=24/8)	eval_scenario (senaryo, n=25/12)
Olay tespiti	23/24 = %96 [%80-%99]	24/25 = %96 [%80-%99]
Kategori adlandırma	9/24 = %38 [%21-%57]	24/25 = %96
Risk kalibrasyonu	20/24 = %83	22/25 = %88
Normal — dar yanlış alarm	0/8	0/12
Normal — yanlış ekip çağırma	0/8	0/12
Normal — operasyonel yanlış alarm	5/8 = %62	4/12 = %33
Gecikme (medyan)	19,35 sn	17,1 sn

Kaynak: eval_20260728_193430.json · eval_20260728_194508.json

Üç ayrı yanlış alarm tanımı vardır ve karıştırılmamalıdır: dar tanım "normal klipte önem veya risk Yüksek'e çıktı mı", sevk tanımı "boşuna ekip çağırıldı mı", operasyonel tanım ise "herhangi bir olay üretildi mi". Üçüncüsü kodda açıkça "dürüst metrik" olarak etiketlenmiştir ve en zayıf rakamdır. Bu belgede bilerek gösterilmektedir.

12.2 · Sorgu A/B — "sorgu filtreler mi?" (eval_scenario)

A: sorgu yok · B: "Sadece forklift hareketlerine bak..." (sette hiç forklift yoktur) · A': A'nın birebir tekrarı.

Ölçüm	A	A'	B
Anomali tespiti (n=25)	24/25 = %96	24/25 = %96	24/25 = %96
Yangın tespiti (n=10)	10/10	10/10	10/10
Yangın kategori adlandırma	10/10	10/10	10/10
Düşme tespiti (n=15)	14/15	14/15	14/15
Kategori adlandırma	23/25 = %92	24/25 = %96	24/25 = %96
Risk kalibrasyonu	22/25 = %88	22/25 = %88	24/25 = %96
Gecikme (medyan)	16,9 sn	17,3 sn	16,6 sn

Kaynak: query_ab_A_20260809_182957.json · query_ab_A_20260809_185259.json · query_ab_B_20260809_184045.json

Eşli test (A'ya karşı B): tespit farkı +%0, aralık [−%16, +%16], $p = 1,0000$. Yani sistemin en dar sorgu altında bile yangını kaçırmadığı ölçülmüştür. Risk kalibrasyonunda B lehine +%8 (22/25 → 24/25) görünüyor; bu fark $b = 0$, $c = 2$ ile $p = 0,50$ 'dir, yani anlamsızdır. Dahası, hiçbir şey değiştirilmeden yapılan A~A' tekrarı aynı metrikte de 2 klip oynamaktadır (Subject3_fall01, Subject3_fall02). İki kliplik bir fark bu sette koşu-arası gürültüden ayrılamaz.

Dürüstlük notu. Tespit ve adlandırmada A~B farkının tamamı A~A' tekrarı da görülür (birebir aynı klipler). Risk kalibrasyonunda ise durum bu kadar temiz değildir: A~B'de ayrışan iki klipten biri (urfd_fall03) A~A'de ayrışmaz. Yani bu metrikte sorguya atfedilebilecek uyumsuzluk sıfır değil, bir kliptir — istatistiksel olarak anlamsız, ama "sıfır" demek yanlış olurdu.

Bu ölçümün en öğretici anı: yanıltıcı kanıt

B kolunda bir düşme klibinin özeti "forklift hareketi gözlemlenmedi, olay yok" diyordu — sorgunun olayı bastırıldığına dair mükemmel bir kanıt gibi görünüyordu. Ancak A' kolu, hiç sorgu almadan aynı klibi kaçırdı. Yani gözlenen şey sorgunun etkisi değil, sonradan gerekçelendirmeydi. Ders: tekrar koşusu olmadan anlatısal kanıt yanıltır.

12.3 · Kural ihlali ölçümü — hedef alan (eval_defense, n=200)

Bu, projenin istatistiksel olarak anlamlı tek büyük sonucudur.

Ölçüm	Kural KAPALI	Kural AÇIK	Fark ve p değeri
Olay tespiti	20/100	47/100	+%27 [%+15, +%38] · p = 4,19e-05 anlamlı
Kategori adlandırma	9/100	33/100	+%24 [%+14, +%34] · p = 8,43e-06 anlamlı
Risk kalibrasyonu	5/100	10/100	+%5 · p = 0,267 anlamsız
Normal — dar yanlış alarm	4/100	8/100	p = 0,125
Normal — operasyonel yanlış alarm	17/100	35/100	p = 0,0014 — anlamlı KÖTÜLEŞME
Gecikme (medyan)	11,7 sn	14,15 sn	+2,45 sn maliyet

Kaynak: eval_20260726_162613.json · eval_20260726_171601.json

Dürüst okuma. Tesise özgü kural bilgisi vermek, görüntüden anlaşılamayan ihlalleri gerçekten görünür kılıyor — bu kazanç büyük ve istatistiksel olarak sağlamdır. Ama bedeli vardır: kural açıkken sistem normal kliplerde de daha çok "olay" üretiyor ve operasyonel yanlış alarm anlamlı biçimde artıyor. Ayrıca %47 bir tavandır: kural verilse bile ihlallerin yarısı kaçırılıyor.

12.4 · Hız, kaynak ve dayanıklılık

Ölçüm	Sonuç
Video saniyesi başına işlem	0,66 sn (aralık 0,37–2,91)
Zamanın nereye gittiği	%98 model çıkarımı · %2 video çözme (toplam 3,4 sn)
Sıralı koşu (4 video)	82,2 sn — video başına 20,5 sn
Eş zamanlı x2	46,7 sn — 5,1 video/dakika · 1,76 kat hızlanma
Eş zamanlı x4	36,8 sn — 6,5 video/dakika · 2,23 kat hızlanma
Tepe VRAM	22.661 MB / 24 GB (model FP8 ~19 GB)
GPU sıcaklığı (uzun koşu)	ortalama 69,8 °C · en yüksek 86 °C · 80 °C üstü 15 örnek

Kaynak: full_20260728_192334/performans.log:5-19 (klip bazlı aralık :5-10, ortalama :11, eş-zamanlılık :15-17, VRAM :19) · benchmark/results/gpu_telemetri_C.csv (209 örnek, 21:47:13–22:04:42 = 17,5 dakika — bu koşumda yeniden hesaplandı)

12.5 · Bağımsız kalite hakemliği

Çıktı kalitesi, sistemi çalıştıran modelden farklı bir modelle puanlanmıştır (Gemma-3-12B). Böylece sistemin kendi kendini puanlaması önlenir. Puanlar iki aileye ayrılır ve birleştirilmez.

DAYANAKLI — klibin bilinen etiketine karşı	Sonuç
Olgusal dayanıklılık (1–5)	4,38 ± 1,14 (n=37 klip)

DAYANAKLI — klbin bilinen etiketine karşı	Sonuç
Etiketle çelişki	3/37 = %8,1 [%2,8-%21,3]
Uydurma ayrıntı	10/37 = %27,0 [%15,4-%43,0]
Kategori bazında dayanaklılık	Yangın $4,70 \pm 0,67$ · Düşme $4,40 \pm 1,12$ · Normal $4,08 \pm 1,44$
İÇ TUTARLILIK — sistemin kendi olay listesine karşı	Sonuç
Özet kalitesi (1-5)	$4,48 \pm 0,63$ (37 klip × 3 eksen)
Aksiyon kalitesi (1-5)	$4,59 \pm 0,58$ (28 klip × 4 eksen)
Risk gerekçesi kalitesi (1-5)	$4,86 \pm 0,47$ (28 klip × 3 eksen)
JSON şema uyumu (holistik karne, 9 klip)	%100

Bu skorların en kritik sınırı

Hakem model videoyu görmüyor (sonuç dosyasında gorsel_dayanak = False olarak kayıtlıdır). İç tutarlılık puanları sistemin videoyu doğru anladığını kanıtlamaz; yalnızca kendi çıktısıyla çelişmediğini gösterir. Kendinden emin bir halüsinasyon bu ölçekte tam puan alabilir. Dış geçerlilik için yalnızca DAYANAKLI bloğuna bakılmalıdır — ve orada en önemli rakam %27 uydurma ayrıntıdır.

12.6 · Testler

Bu koşumda bütün test dosyaları yeniden çalıştırılmıştır (GPU gerekmez):

Test dosyası	Kontrol	Kapsam
tests/test_query_driven.py	183	Sorgu-güdümlü analiz, enjeksiyon direnci, sözleşme izolasyonu
tests/test_kusur2_severity.py	94	Kural hakemliği ve önem yükseltme mekanizması
tests/test_rescore.py	91	Yeniden skarlama aracı ve eşleştirici
tests/test_mock_mode.py	56	GPU'suz demo modu
tests/test_capraz_dogrulama.py	44	Belgeler arası çapraz doğrulama
tests/test_agent_k2_k4_k5.py	40	Ajan davranışı
tests/test_agent_k1_k3_k6.py	32	Kayıt izolasyonu, sözleşme, hata toleransı
Toplam	540	0 hata — ayrıca ölçüm araçlarının kendi 27 birim testi de geçti

13. Denediğimiz veelediğimiz yollar

Bu bölüm bilerek uzun tutulmuştur. Bir yöntemin işe yaramadığını ölçmek, işe yaradığını ölçmek kadar değerlidir; ve bir projenin bilimsel dürüstlüğü en iyi burada görülür. Her madde: ne denendi, ne çıktı, neden vazgeçildi.

13.1 · Daha büyük / farklı model

Denenen	Sonuç ve karar
Qwen2.5-VL-32B-AWQ	Hiç çalışmadı. Ağırlıklar 24 GB'a sığdı ama KV önbelleğine yer kalmadı. Donanım sınırı.
InternVL3.5-14B-AWQ	Sığdı ama daha kötü ve daha yavaş: Türkçesi kirli, normal kliplerde yanlış alarm %12, video saniyesi başına ~3,05 sn (Qwen ~1,4 sn). Elendi.
Sınır modeller taraması (2026)	InternVL3.5, MiniCPM-V4.5, GLM-4.6V, Ovis2.5, Keye-VL, VideoLLaMA3 literatürden incelendi; hiçbir bu donanımda koşturulmadı. O günkü gerekçemiz "darboğaz model kapasitesi değil, 320×240 karede bulunmayan bilgidir" idi. Bu gerekçe bugün kısmen geri çekilmiştir — bkz. 13.5. Karar (model yükseltmesi yapmamak) korunmuştur, ama dayanağı artık ölçülmüş bir sonuç değil, ölçülmemiş bir beklentidir.

Neden bu satırın dayanağı zayıfladı

"Darboğaz tamamen görseldir" iddiasının birincil kanıtı, taksonomi kelimelerini modele vermenin adlandırmayı hiç değiştirmediyi gözlemiydi. 13.5'te gösterildiği gibi o ölçüm hatalıydı: doğru skorlamayla model taksonomiye kullandı (12/24'e karşı 14/24). Dolayısıyla bugün ne "darboğaz tamamen görseldir" ne de "sözcükseldir" denebilir; n=24'te ayırtılamıyor. Yalnızca Silahlı olay için görsel sınır iddiası ayakta kalır (14.1) — çünkü orada taksonomi verildiği hâlde üç kolun ve dört skorlama kuralının hepsinde 0/3 alınmıştır.

13.2 · Görüntü ön işleme

Denenen	Sonuç ve karar
CLAHE kontrast iyileştirme	Tespit %96'da aynı, kategori %25'te aynı; risk kalibrasyonu düştü, gecikme arttı. Ders: düşük çözünürlük tavanı kontrastla aşılmıyor. Varsayılan kapalı.
Çözünürlük ve kare sayısı artırma (768→1280, 16 kare)	Bağlam bütçesini aşıp hata verdi. Aynı belge ailesinde bu maddeye "+0,69 puan" atfeden bir tablo da vardır; o rakamın birincil ölçüm kaydı depoda bulunamamıştır ve bu belgede kullanılmamaktadır.
Süper-çözünürlük	Bir özet tabloda "kanıtla elenmiş" diye geçmektedir, ancak depoda hiçbir betik, koşu dosyası veya ölçüm satırı yoktur. Bu belgede doğrulanamamış olarak işaretlenmektedir; savunulabilir bir bulgu değildir.

13.3 · Yönerge (prompt) düzeyinde denemeler

Denenen	Sonuç ve karar
Aksiyon-ipucu kontrol listesi + taksonomi tanımları	Net gerileme: tespit %96→%92, risk kalibrasyonu %46→%33, kategori %25→%12. Sistem "aşırı temkinli" oldu. Temel yapılandırmaya geri alındı.
Zamansal akıl yürütme zinciri (başlangıç→gelişim→sonuç)	Yukarıdakiyle birlikte risk kalibrasyonunu %46'dan %33'e düşürdü. Geri alındı.
Yönergeye doğrudan önem talimatı yazmak ("bu ihlaller en az YÜKSEK olmalıdır")	Risk kalibrasyonu 5/100→10/100, p = 0,267 anlamsız. Sonuç: risk yükseltme yönerge katmanında çözilemiyor.

13.4 · En büyük negatif sonuç: politika hakemliği

Ne denendi. Operatör satır başına kural beyan ediyor; sistem video başına tek bir anlamsal sınıflandırma çağrısıyla olayları kurallarla eşleştiriyor ve eşleşirse önemi kuralın beyan ettiği seviyeye yükseltiyor. Dört ayrı kapı kurulmuştu: kapsam, kanıt alıntısı doğrulama, çekince filtresi, bütçe.

Ne çıktı. $n=200$ eşli ölçümde risk kalibrasyonu 10/100'den 14/100'e çıktı, $p = 0,48$. Kabul kapısı ($\geq 20/100$ ve $p < 0,05$) geçilemedi.

Kök neden ölçüldü, tahmin edilmedi. Mekanizma mekanik olarak doğru çalıştı — 91 klipte devreye girdi. Ama yedi yükseltmenin yedisi de aynı kurala eşleşti; diğer üç kurala sıfır. En çarpıcı örnek: "forklift aşırı yük taşıyor" olayı, tam karşılığı olan aşırı yük kuralıyla hiç eşleşmedi. Ayrıca yedi yükseltmenin üçü normal kliplerdeydi.

Buradan çıkan ders

8B'lık bir model açık uçlu kural eşleştirme görevini yapamıyor. Kurduğumuz kapılar uydurma kanıtı eliyor, ama "yanlış ama sadık alıntılı" yargıyı elemiyor — model gerçekten gördüğü bir şeyi alıntılıyor, sadece yanlış kurala bağlıyor. Hata mekanizmada değil modelin yargısında olduğu için kod ve onun 94 kontrollük testi korunmuştur; mekanizma varsayılan kapalıdır.

İkinci ve daha rahatsız edici bulgu: mekanizmanın hiç dokunmadığı metrikler de oynadı — tespit 14 klip düştü, 17 klip yükseldi. Bu, koşullar arasında ± 15 kliplik bir salınım olduğu anlamına gelir ve determinizm sorunu çözülmeden bu mekanizmanın herhangi bir düzeltmesinin doğrulanamayacağını gösterir.

13.5 · Ölçüm zincirinin kendisindeki kusur ve onarımı

Bu, projenin en öğretici bölümüdür: ölçüm aracının kendisi hatalıydı. Kategori adlandırma metriği yalnızca olay listesindeki kısa açıklamayı tarıyordu; oysa özet alanı hem çıktı sözleşmesinin parçası hem de operatörün ekranda okuduğu asıl metindir. Eşleştirici ayrıca çok gevşekti — gerçek örnekler:

Metin	Yanlış eşleşme	Neden yanlış
"kırmızı sıvı dökülmüş"	Vandalizm	"kır" kökü çıplak alt dize olarak arandığı için
"vurgulanmadı"	Saldırı	aynı kusur
"kaza belirtisi YOK"	Trafik kazası	olumsuzlama görmezden gelindiği için
"İstismar" küçük harfe çevrilince	hiçbiri	Türkçe büyük İ, birleştirici noktayla küçülüyor ve eşleşmiyor

Onarım nasıl yapıldı. Dört skorum kuralı tanımlandı ve arşivdeki sonuçlar modeli hiç çalıştırmadan yeniden skorlandı. Aşağıdaki tabloyu bu koşumda benchmark/rescore.py ile birebir yeniden ürettim:

Skorlama kuralı	A	B	C	Özgüllük A / B / C
1 — ESKİ (yalnız olay alanı, çıplak alt dize)	9/24 %37,5	10/24 %41,7	8/24 %33,3	2,67 / 1,92 / 2,25
2 — + özet alanı, aynı gevşek eşleştirici	12/24 %50,0	12/24 %50,0	14/24 %58,3	3,12 / 2,58 / 3,33
3 — + özet + sıkılaştırılmış eşleştirici	11/24 %45,8	11/24 %45,8	12/24 %50,0	2,04 / 1,62 / 2,12
4 — kural 3 + semantik gruptama	14/24 %58,3	11/24 %45,8	12/24 %50,0	1,29 / 1,08 / 1,29

Özgüllük = klip başına tetiklenen yanlış kategori sayısı (düşük iyidir). Hat doğrulaması: kural 1, üç dosyada da kayıtlı eski değeri 24/24 birebir yeniden üretti.

Kural 2'den 3'e düşüş bir gerileme değil, bir itiraftır. Özet alanını eklemenin getirdiği kazancın bir kısmı şans eseri alt dize tutturmasıydı. Sıkılaştırma o sahte kazancı geri aldı ve özgüllüğü belirgin biçimde iyileştirdi (2,67→2,04). Sonuç: onarım, ölçüm tabanını %38'den %46'ya taşıdı. Bu bir iyileştirme değil, bir düzeltmedir — model hiç değişmedi.

Geri çekilen iddia — nasıl yanlışlığımızın kaydı

Önceki bir ölçüm şunu iddia etmişti: "taksonomi kelimesi geçen klip sayısı iki kolda birebir aynı, demek ki model cevap anahtarını kullanmadı; darboğaz sözcüksel değil görsel." Bu kontrol varlık sayıyordu (herhangi bir taksonomi kelimesi geçti mi), oysa ölçülmesi gereken doğruluktaki. Doğru ölçümle: 12/24'e karşı 14/24 — model taksonomi kullandı. Kazanç özet alanında kaldı, olay listesine giremedi. Yanlış iddia silinmedi; "nasıl yanlışlığımızın kaydı" olarak depoda duruyor. Aynı ölçümün "metrik kelime hazırlamayla şişirilemez" maddesi de geri çekildi.

13.6 · Literatürden alınıp bizde tutmayan yöntem

Semantik gruptama. Yayımlanmış bir çalışma (arXiv 2511.07171, Ovis-8B / UCF-Crime) kategorileri anlamsal gruplara indirmenin eğitim yapmadan +15,7 puan getirdiğini bildiriyor. Bizde aynı fikir kural 4 olarak ölçüldü: A kolunda +12,5 puan, B ve C kollarında 0,0 puan — ortalama +4,2 puan, yani vaat edilenin dörtte biri. Üstelik tek pozitif sonuç yalnızca 3 klipten ibaret ve gürültü tabanının sınırında.

Sebepler tahmin edilmedi, ölçüldü. İlk hipotezimiz "grup içi kelime dağarcıkları örtüşüyor, katman etkisiz kalıyor" idi ve yanlış çıktı (ölçülen grup içi örtüşme küçüktü). Gerçek sebep, kuralın

değiştirdiği kliplerin tek tek listelenmesiyle bulundu: gruplama yalnızca hata grubun içinde kaldığında işe yarıyor. A kolunda kalan hatalar grup içindeydi (kavga/istismar karışması), B ve C kollarında ise gruplar arasıydı.

13.7 · İsteğe bağlıya düşürülenler

Özellik	Neden varsayılan değil
Video belirteci budama	Yalıtılmış ölçümde tarif adımını %40 hızlandırdı, ama tam akışta kazanç ~0 ve normal yanlış alarm arttı.
Toplu doğrulama	Çok olaylı videolarda gecikmeyi %24 düşürüyor, ancak doğruluk etkisi kanıtlanmadı.
Risk geri-çağırma eğilimi	Görünen +12 kazanç gürültü çıktı (risk kalibrasyonuna katkı +0).
Nörosimbolik olabilirlik kontrolü	Grenli görüntüde YOLO kişi tespiti güvenilirmez; tespit kaybı riski.
Kalıcı önem yükseltme	Ölçümde dar yanlış alarmı 0'dan 12'ye çıkardı — reddedildi.

Ayrıca ortam duvarına takılan iki deneme vardır: yeni model çalıştırıcı sürümü (WSL2 GPU geçişi gereken birleşik adresleme desteğini sağlamıyor) ve FP8 KV önbelleği (bağlayıcı/ortam reddi). Bunlar doğruluk değil ortam kısıtlarıdır. Bir de kayıtlı günlüğü bulunamadığı için geri çekilmiş bir iddia vardır: sunucu bayrağı turunun getirdiği söylenen %24 verim artışı.

14. Bilinen sınırlar

Aşağıdakiler tahmin değil, ölçülmüş sınırlardır. Bilerek ve açıkça raporlanmaktadır.

14.1 · Yetenek sınırları

Sınır	Ölçülen durum
Silahlı olay (Shooting) 0/3	Üç A/B kolunda ve dört skorlama kuralının hepsinde 0/3. Model olayı görüyor (tespit tam) ama "silahlı" demiyor: "iki kişi arasında fiziksel temas ve itme", "bir kişi ani şekilde yere düşmüş" diyor. Semantik gruplama da kurtaramıyor çünkü "Silahlı" tek üyeli bir gruptur. Yayımlanmış bir çalışma (arXiv 2303.10703) UCF'nin 320×240 karelerinde tabancaların yaklaşık 16 piksel olduğunu ölçüyor — bilgi karede fiziksel olarak yoktur.
Grenli görüntüde tür adlandırma	İyimser sayı %38, onarılmış ölçümle %46. Kategori kırılımı: Patlama 3/3, Trafik kazası 2/3, Saldırı 2/3, Kavga 1/3, Hırsızlık 1/3, İstismar 0/3, Vandalizm 0/3, Silahlı 0/3.
Özette uydurma ayrıntı	10/37 = %27 [%15-%43]. Yani yaklaşık her dört özette birinde görüntüde olmayan bir ayrıntı bulunuyor. Ana olay doğru, ayrıntı ekleniyor. Bu, belgedeki en önemli tek zayıflıktır.
Tesise özgü kural ihlali	Kural verilse bile tavan %47 — ihlallerin yarısı kaçırılıyor. Risk kalibrasyonu bu olaylarda %10.
Gece, kızılötesi, termal	Sıfır kapsam. Bütün setler gündüz/aydınlatılmış görünür ışıktır. "Muhtemelen çalışır" demiyoruz.
Forklift devrilmesi	Şartnamenin örneklediği tam bu olay için gerçek açık veri yoktur. En yakın kanıt devrilme değil, devrilme öncesidir (aşırı yük taşıma).

14.2 · Ölçüm sınırları

- Küçük örneklem. Ana setlerde $n=24$ ve $n=25$ anomali vardır. Tek klip oranı belirgin biçimde oynatır; bu boyutta sıralama karşılaştırması yapılamaz.
- Gürültü tabanı. Tespitte %8, adlandırmada %12. Bundan küçük hiçbir etki bu setlerde ayırt edilemez.
- Güç yetersizliği. Adlandırma A/B'si için mevcut n 'de istatistiksel güç yalnızca %1; %80 güç için gereken klip sayısı 597. Yani "etki yok" değil, "ölçülebilir etki yok" doğrudur.
- İnsan altın cetveli yok. Onarılmış %46'nın gerçekten doğru olduğunu bilmiyoruz; yalnızca eski %38'den daha az yanlış olduğunu biliyoruz. 24 klip üç kişi tarafından bir saatte hakem edilebilir — bu yapılmadı.
- Tespit tanımı gevşek. Manşet "tespit" rakamı yalnızca "en az bir olay üretildi mi" demektir; tür doğruluğu aranmaz. Üç seviyeli dürüst okuma (51 bağımsız klip): TESPİT 49/51 = %96 · AKSİYON 36/51 = %71 · TANIMA 22/51 = %43.
- Hakem videoyu görmüyor. İç tutarlılık skorları dış geçerlilik kanıtı değildir. Diyalog ölçümü ayrıca tavana doygundur (hakem her maddeye tam puan vermiş, standart sapma sıfır) — ayırım gücü yoktur, kusursuzluk kanıtı değildir.
- Onarılmış metrikle canlı koşu yok. %46 rakamı arşiv yeniden skorlamasından gelmektedir; yeni kuralla üretilmiş taze bir GPU koşusu henüz yapılmamıştır. Ayrıca senaryo seti bu onarımdan sonra yeniden ölçülmemiştir — oradaki %92-96 rakamları hâlâ eski kuraldır.
- Tek donanım, tek dil, tek operatör. Tek GPU, tek model, Türkçe. Farklı kart, sürücü veya niceleme altında yeniden üretim test edilmemiştir.

14.3 · Bu sistem ne için KULLANILMAZ

- Otonom alarm veya insan onayı olmadan otomatik ekip sevki
- İnsansız gece vardiyası (gece/termal kapsam sıfırdır)
- Tesise özgü politika denetiminin tek dayanağı olmak (tavan %47)
- Silah veya ince tehdit tespiti (0/3, yapısal sınır)

15. Yol haritası

Sıradaki adımlar, yukarıdaki sınırların doğrudan karşılığıdır:

Sıra	Adım	Hangi sınırı kapatır
1	Determinizmi sabitlemek — toplu işlem boyutunu sabitleyip koşu-arası salınımı düşürmek.	Gürültü tabanı %8/%12 olduğu sürece hiçbir küçük iyileştirme doğrulanamıyor. Bu, diğer bütün adımların önkoşuludur.
2	İnsan altın cetveli — 24 klibi üç değerlendiriciyle hakem etmek.	Onarılmış adlandırma metriğinin gerçekten doğru olup olmadığını bilmiyoruz.
3	Onarılmış metrikle taze koşu — holdout ve senaryo setlerini yeni skollama kuralıyla yeniden ölçmek.	Bugünkü %46, arşiv yeniden skollamasından geliyor; canlı koşu yok.
4	Uydurma ayrıntıyı azaltmak — özet üretiminde dayanaklandırma kısıtlarını sıkılaştırmak.	%27 uydurma ayrıntı, kalite tarafındaki en büyük tek açık.
5	Örneklem büyütme — adlandırma A/B'si için gereken klip sayısı ölçüldü: 597.	Mevcut güç %1; bu haliyle hiçbir adlandırma müdahalesi kanıtlanamaz.
6	Gece / kızılötesi kapsamı — bu koşullarda veri toplamak ve ölçmek.	Bugün sıfır kapsam var; sistem bu koşullarda hiç test edilmedi.
7	Bağımlılık ve belge açıklarını kapatmak — ultralytics'i gereksinim dosyalarına eklemek, arayüz adım göstergesine policy_gate'i yansıtmak, yönlendirici açıklama metnini davranışla uyumlamak, kaynağı bulunamayan "süper-çözünürlük" iddiasını tablodan çıkarmak.	Bu belgede tespit edilen, kod ile belge arasındaki tutarsızlıklar.

Kapanış. Bu belgedeki her sayı depodaki bir dosyadan okunmuştur ve yeniden üretilebilir. Ölçümler benchmark/results/ altında ham JSON olarak durur; skollama benchmark/rescore.py ile model çalıştırmadan yeniden hesaplanabilir; testler tests/ altındadır. Sayı verilemeyen yerlerde cümle sayısız bırakılmıştır — bir rakamı savunamıyorsak yazmıyoruz.